

第3章 支持向量机

刘家锋

哈尔滨工业大学

第3章 支持向量机

① 3.1 最优超平面与支持向量机

② 3.2 对偶问题

③ 3.3 软间隔与正则化

④ 3.4 核函数


⑤ 3.5 支持向量机回归

3.1 最优超平面与支持向量机

最优分类超平面

● 线性分类器的优劣


- 对于线性可分的训练样例来说，分类超平面 H_1 和 H_2 是等价的，都能正确分类所有样例；



最优分类超平面

● 线性分类器的优劣


- 对于线性可分的训练样例来说，分类超平面 H_1 和 H_2 是等价的，都能正确分类所有样例；
- 对于未来的测试样例来说，距离训练样例更近的超平面 H_2 产生错误分类的风险更大；



线性判别函数与超平面

● 分类超平面

- 给定线性判别函数： $g(\mathbf{x}) = \mathbf{w}^t \mathbf{x} + b$
- 分类超平面 H 上的点满足方程： $g(\mathbf{x}) = 0$
- 分类超平面将空间划分为两个区域，分别代表两个类别；



样例到超平面的距离

- 空间中任意点 \mathbf{x} 到超平面 H 的距离: $r = g(\mathbf{x})/\|\mathbf{w}\|$

- 首先证明权值向量 \mathbf{w} 垂直于超平面 H :

$\forall \mathbf{x}_p, \mathbf{x}_q \in H$, 满足超平面方程: $\mathbf{w}^t \mathbf{x} + b = 0$

$$\mathbf{w}^t (\mathbf{x}_p - \mathbf{x}_q) = \mathbf{w}^t \mathbf{x}_p + b - (\mathbf{w}^t \mathbf{x}_q + b) = 0$$

因此有, \mathbf{w} 正交于向量 $\mathbf{x}_p - \mathbf{x}_q$; 由 \mathbf{x}_p 和 \mathbf{x}_q 的任意性, 证明 \mathbf{w} 正交于超平面 H ;

- 计算点到超平面的距离:

令 $\mathbf{x}_p \in H$ 为 \mathbf{x} 向 H 所引垂线的垂足, \mathbf{x} 到 H 的距离为 r

$$\overrightarrow{O\mathbf{x}} = \overrightarrow{O\mathbf{x}_p} + \overrightarrow{\mathbf{x}_p\mathbf{x}} \implies \mathbf{x} = r \cdot \mathbf{w}/\|\mathbf{w}\| + \mathbf{x}_p$$


因此:

$$\begin{aligned} g(\mathbf{x}) &= \mathbf{w}^t (r \cdot \mathbf{w}/\|\mathbf{w}\| + \mathbf{x}_p) + b \\ &= r\|\mathbf{w}\| + (\mathbf{w}^t \mathbf{x}_p + b) = r\|\mathbf{w}\| \end{aligned}$$

最优分类超平面

● 最优分类超平面

- 样例集与分类超平面之间的间隔 γ ：样例到分类超平面距离的最小值；
- 最优分类超平面：能够将样例集区分开的最大间隔超平面；



最优分类超平面

● 支持向量

- 支持向量(Support Vector): 距离分类超平最近的训练样本;
- 支持面: 支持向量所在的平行于最优分类超平面的超平面;
- 在最优分类超平面两侧各有一个支持面, 与最优分类超平面的距离均为 γ ;

● 支持向量机(Support Vector Machine)的学习问题

- 给定二分类数据集: $D = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_m, y_m)\}$, 类别标记 $y_i \in \{-1, +1\}$;
- 学习判别函数 $g(\mathbf{x}) = \mathbf{w}^t \mathbf{x} + b$, 能够正确区分训练样例集, 并且与样例集的间隔最大, 即最优分类界面;

SVM的优化目标函数

● 最优超平面的条件

- 当判别函数 $g(\mathbf{x})$ 能够正确区分训练样例时，有下式成立：

$$y_i(\mathbf{w}^t \mathbf{x}_i + b) \geq \min_{1 \leq j \leq m} [y_j(\mathbf{w}^t \mathbf{x}_j + b)] = z_{min} > 0$$

- 令 $\mathbf{w} \leftarrow \mathbf{w}/z_{min}, b \leftarrow b/z_{min}$ ，不会改变分类超平面的位置；
- 满足下述条件的判别函数，能够将训练样例正确分类：

$$y_i(\mathbf{w}^t \mathbf{x}_i + b) \geq 1, \quad i = 1, \dots, m$$

SVM的优化目标函数

● 最大化间隔

- 最靠近分类超平面的样例到超平面的距离： $z_{min} = 1$ ，因此间隔：

$$\gamma = \frac{1}{\|\mathbf{w}\|}$$

- 最大化间隔 γ ，等价于最小化权值向量的长度 $\|\mathbf{w}\|$ ；

● SVM的优化问题

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2$$

subject to

$$y_i(\mathbf{w}^t \mathbf{x}_i + b) \geq 1, \quad i = 1, \dots, m$$

凸二次规划问题可以直接优化计算，但也存在更高效的办法；

3.2 对偶问题

约束优化问题的求解

● Min-Max原理

- SVM是一个典型的线性不等式约束的二次优化问题；
- 下面引用John von Neumann的Min-Max原理，来说明约束优化问题的求解方法；
- 对于函数 $F(\mathbf{u}, \mathbf{v})$ ，有如下两个优化问题：

$$\text{Min-Max: } \begin{cases} F^*(\mathbf{u}) = \max_{\mathbf{v}} F(\mathbf{u}, \mathbf{v}) \\ \min_{\mathbf{u}} F^*(\mathbf{u}) = \min_{\mathbf{u}} \max_{\mathbf{v}} F(\mathbf{u}, \mathbf{v}) \end{cases}$$

$$\text{Max-Min: } \begin{cases} F^*(\mathbf{v}) = \min_{\mathbf{u}} F(\mathbf{u}, \mathbf{v}) \\ \max_{\mathbf{v}} F^*(\mathbf{v}) = \max_{\mathbf{v}} \min_{\mathbf{u}} F(\mathbf{u}, \mathbf{v}) \end{cases}$$

- 如果两个问题的解存在，必在同一点取得最优解：

$$\min_{\mathbf{u}} \max_{\mathbf{v}} F(\mathbf{u}, \mathbf{v}) = \max_{\mathbf{v}} \min_{\mathbf{u}} F(\mathbf{u}, \mathbf{v}) = F(\mathbf{u}^*, \mathbf{v}^*)$$

Kuhn-Tucker构造法

● SVM的原始优化问题

$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \frac{1}{2} \|\mathbf{w}\|^2 \\ \text{subject to} \quad & y_i(\mathbf{w}^t \mathbf{x}_i + b) \geq 1, \quad i = 1, \dots, m \end{aligned}$$

● 构造Lagrange函数:

$$L(\mathbf{w}, b, \boldsymbol{\alpha}) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^m \alpha_i [y_i(\mathbf{w}^t \mathbf{x}_i + b) - 1]$$

其中, $\alpha_i \geq 0$ 称为Lagrange乘数, 第2项的最小值为0, 因此有:

$$\max_{\{\alpha_i \geq 0\}} L(\mathbf{w}, b, \boldsymbol{\alpha}) = \frac{1}{2} \|\mathbf{w}\|^2$$

Kuhn-Tucker构造法

- 原始优化问题到对偶优化问题

- SVM的原始优化问题等价于：

$$\min_{\mathbf{w}, b} \max_{\{\alpha_i \geq 0\}} L(\mathbf{w}, b, \boldsymbol{\alpha})$$

- 根据Min-Max原理：

$$\min_{\mathbf{w}, b} \max_{\{\alpha_i \geq 0\}} L(\mathbf{w}, b, \boldsymbol{\alpha}) = \max_{\{\alpha_i \geq 0\}} \min_{\mathbf{w}, b} L(\mathbf{w}, b, \boldsymbol{\alpha})$$

- 优化次序可以互换，Lagrange函数先对 \mathbf{w}, b 优化；

Kuhn-Tucker构造法

● 原始优化问题到对偶优化问题

○ Lagrange函数的最小值优化:

$$\min_{\mathbf{w}, b} L(\mathbf{w}, b, \alpha) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^m \alpha_i [y_i(\mathbf{w}^t \mathbf{x}_i + b) - 1]$$

○ 计算极值点条件:

$$\frac{\partial L}{\partial \mathbf{w}} = \mathbf{w} - \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i = \mathbf{0} \quad \Rightarrow \quad \mathbf{w} = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i$$

$$\frac{\partial L}{\partial b} = - \sum_{i=1}^m \alpha_i y_i = 0 \quad \Rightarrow \quad \sum_{i=1}^m \alpha_i y_i = 0$$

Kuhn-Tucker构造法

● 原始优化问题到对偶优化问题

- 将 $\mathbf{w} = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i$ 带入Lagrange函数:

$$\begin{aligned} L(\alpha) &= \frac{1}{2} \mathbf{w}^t \mathbf{w} - \sum_{i=1}^m [\alpha_i y_i \mathbf{w}^t \mathbf{x}_i + \alpha_i y_i b - \alpha_i] \\ &= \frac{1}{2} \left(\sum_{i=1}^m \alpha_i y_i \mathbf{x}_i \right)^t \left(\sum_{i=1}^m \alpha_i y_i \mathbf{x}_i \right) \\ &\quad - \sum_{i=1}^m \left[\alpha_i y_i \left(\sum_{j=1}^m \alpha_j y_j \mathbf{x}_j \right)^t \mathbf{x}_i + \alpha_i y_i b - \alpha_i \right] \end{aligned}$$

- 利用 $\sum_{i=1}^m \alpha_i y_i = 0$, 化简得到:

$$L(\alpha) = -\frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^t \mathbf{x}_j + \sum_{i=1}^m \alpha_i$$

Kuhn-Tucker构造法

● SVM的对偶优化问题

- 得到与原始优化问题等价的对偶优化问题：

$$\max_{\alpha} L(\alpha) = \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \mathbf{x}_i^t \mathbf{x}_j$$

subject to

$$\sum_{i=1}^m \alpha_i y_i = 0$$

$$\alpha_i \geq 0, \quad i = 1, \dots, m$$

- 优化对偶问题的好处：
 - 优化变量简单，只有Lagrange乘数 α ；
 - 只需要计算任意两个特征矢量的内积： $\mathbf{x}_i^t \mathbf{x}_j$

3.3 软间隔与正则化

软间隔

● 松弛变量

- 对于线性不可分的训练集，不等式约束不可能全部被满足；
- 引入“松弛变量” $\xi_i \geq 0$ ，将不等式约束变为：

$$y_i(\mathbf{w}^t \mathbf{x}_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0$$

- 只要选择一系列适合的松弛变量 ξ_1, \dots, ξ_n ，不等式约束条件总是可以得到满足的；
- 好的判别函数能够正确分类更多的样本，因此希望更多松弛变量 $\xi_i = 0$ ；
- 优化目标需要同时考虑分类界面的几何间隔，以及松弛变量的大小；

软间隔

● 软间隔SVM的原始优化问题

$$\min_{\mathbf{w}, b, \xi} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \xi_i$$

subject to

$$\begin{aligned} y_i(\mathbf{w}^t \mathbf{x}_i + b) &\geq 1 - \xi_i, \quad i = 1, \dots, m \\ \xi_i &\geq 0, \quad i = 1, \dots, m \end{aligned}$$

其中，参数 C 用来协调两个优化目标，需要设置；

○ 构造Lagrange函数

$$\begin{aligned} L(\mathbf{w}, b, \xi, \alpha, \beta) &= \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \xi_i \\ &\quad - \sum_{i=1}^m \alpha_i [y_i(\mathbf{w}^t \mathbf{x}_i + b) - 1 + \xi_i] - \sum_{i=1}^m \beta_i \xi_i \end{aligned}$$

线性不可分的训练集

● 软间隔SVM的对偶优化问题

- 采用Kuhn-Tucker构造法，可以得到对偶优化问题：

$$\max_{\alpha} L(\alpha) = \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^t \mathbf{x}_j$$

subject to

$$\sum_{i=1}^m \alpha_i y_i = 0$$

$$C \geq \alpha_i \geq 0, \quad i = 1, \dots, m$$

与线性可分情况相比，对偶优化问题只是增加了 α_i 上界的约束；

SVM的优化求解

● SVM的优化求解方法

- SVM的原始问题和对偶问题都是典型的二次凸优化，存在唯一解，一般选择比较简单的对偶问题求解；
- 针对SVM的学习，存在专门的有效算法：序列最小化算法(SMO算法)；
- 在大多数的机器学习软件包中都有相应的功能，例如Matlab 2019中的fitcsvm：

```
svm = fitcsvm( X,Z,'KernelFunction','linear','BoxConstraint',1 );
Label = predict( svm,x );
```

Lagrange乘数与支持向量

● 支持向量

- 对偶问题的解是 m 个Lagrange乘数 $\{\alpha_1, \dots, \alpha_m\}$;
- 根据Kuhn-Tucker定理, 有如下关系成立:

$$\begin{cases} y_i(\mathbf{w}^t \mathbf{x}_i + b) > 1, & \alpha_i = 0 \\ y_i(\mathbf{w}^t \mathbf{x}_i + b) = 1, & C > \alpha_i > 0 \\ y_i(\mathbf{w}^t \mathbf{x}_i + b) < 1, & \alpha_i = C \end{cases}$$

- 其中, 满足条件2, 3的训练样本称为支持向量;


Lagrange乘数与支持向量

● 非支持向量

- 支持面之外: $\alpha_i = 0$

● 支持向量

- 支持面之上: $C > \alpha_i > 0$
- 支持面之内: $\alpha_i = C$
- 错误分类样本: $\alpha_i = C$



Lagrange乘数与支持向量

● Kuhn-Tucker条件的简单解释

- 从Lagrange函数来看：

$$\min_{\mathbf{w}, b, \xi} \max_{\alpha, \beta} L(\mathbf{w}, b, \xi, \alpha, \beta) = \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \xi_i$$

$$- \sum_{i=1}^m \alpha_i [y_i (\mathbf{w}^t \mathbf{x}_i + b) - 1 + \xi_i] - \sum_{i=1}^m \beta_i \xi_i$$

- 关于 ξ_i 的极值条件：

$$\frac{\partial L}{\partial \xi_i} = C - \alpha_i - \beta_i = 0$$

Lagrange乘数与支持向量

● Kuhn-Tucker条件的简单解释

- $y_i(\mathbf{w}^t \mathbf{x}_i + b) > 1$ 时
 - 只有 $\alpha_i = 0$, $L(\mathbf{w}, b, \xi, \alpha, \beta)$ 才能取得最大值;
- $y_i(\mathbf{w}^t \mathbf{x}_i + b) = 1$ 时
 - 允许 $\alpha_i > 0$;
 - $\xi_i = 0$, $L(\mathbf{w}, b, \xi, \alpha, \beta)$ 取得最小值;
 - 对应 $\beta_i > 0$, 有 $\alpha_i = C - \beta_i < C$;
- $y_i(\mathbf{w}^t \mathbf{x}_i + b) < 1$ 时
 - $\xi_i > 0$, 不等式条件才能满足;
 - 对应 $\beta_i = 0$, 有 $\alpha_i = C - \beta_i = C$;

SVM的判别函数

● Kuhn-Tucker条件的简单解释

- 通过对偶问题的求解，可以得到对应每个训练样本的最优Lagrange乘数： $\{\alpha_1, \dots, \alpha_m\}$;
- 判别函数的权值向量 \mathbf{w} ，可以由原始问题的极值条件得到：

$$\mathbf{w} = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i$$

- 处于支持面上的样本 \mathbf{x}_i 与判别界面的函数间隔为1，并且对应的Lagrange乘数满足： $C > \alpha_i > 0$;
- 判别函数的偏置可以由任意的支持面上的训练样本计算：

$$y_i(\mathbf{w}^t \mathbf{x}_i + b) = 1 \quad \Rightarrow \quad b = y_i - \mathbf{w}^t \mathbf{x}_i$$

损失函数和正则项

● hinge损失函数

- 软间隔SVM的优化目标还可以用hinge loss函数表示：

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m l_{hinge}(y_i(\mathbf{w}^t \mathbf{x}_i + b))$$

其中： $l_{hinge}(z) = \max(0, 1 - z)$

● 正则项

- 统计学习模型的更一般形式：

$$\min_f \Omega(f) + C \sum_{i=1}^m l(f(\mathbf{x}_i), y_i)$$

- 第一项称为正则项，控制模型的复杂度；
- 第二项称为经验风险，是模型在训练数据上的损失；
- 参数 C ，调和两者的重要程度；


3.4 核函数

空间的非线性映射

● 非线性映射

- 低维空间线性不可分的数据，非线性地映射到高维特征空间，可以变为线性可分的数据；
- 例如， $R^2 \rightarrow R^3$ 的非线性映射：

$$\phi : (x_1, x_2)^t \rightarrow (x_1^2, \sqrt{2}x_1x_2, x_2^2)^t$$



特征空间中的内积

● 高维特征空间中计算内积

$$\begin{aligned}
 \phi(\mathbf{x})^t \phi(\mathbf{y}) &= (x_1^2, \sqrt{2}x_1x_2, x_2^2)(y_1^2, \sqrt{2}y_1y_2, y_2^2)^t \\
 &= x_1^2y_1^2 + 2x_1x_2y_1y_2 + x_2^2y_2^2 \\
 &= (x_1y_1 + x_2y_2)^2 \\
 &= (\mathbf{x}^t \mathbf{y})^2
 \end{aligned}$$

● 输入空间中计算特征空间内积

- 定义核函数: $\kappa(\mathbf{x}, \mathbf{y}) = (\mathbf{x}^t \mathbf{y})^2$
- 特征空间中向量的内积可以直接在输入空间计算:

$$\phi(\mathbf{x})^t \phi(\mathbf{y}) = \kappa(\mathbf{x}, \mathbf{y})$$

特征空间中的内积

● 特征空间中的计算

- 输入空间向量 $\mathbf{x}, \mathbf{y} \in R^d$ 映射到特征空间 $\phi(\mathbf{x}), \phi(\mathbf{y}) \in R^D$;
- 特征空间中计算向量的内积 $\phi(\mathbf{x})^t \phi(\mathbf{y})$;
- 计算复杂度与特征空间的维数 $D (\gg d)$ 相关;
- 当 $D \rightarrow +\infty$ 时, 很难在特征空间中计算内积;

● 输入空间中的计算

- 只需计算定义在输入空间向量 \mathbf{x}, \mathbf{y} 上的核函数 $\kappa(\mathbf{x}, \mathbf{y})$;
- 计算复杂度只与输入空间的维数 d 相关;

核函数方法

● 核函数的应用

- 在输入空间定义核函数 $\kappa(\mathbf{x}, \mathbf{y})$;
- 线性方法中的向量内积, 使用核函数计算;

● 应用条件

- 定义的核函数对应特征空间中的内积;
- 线性方法不需要特征空间中的向量 $\phi(\mathbf{x})$, 只需要计算向量的内积 $\phi(\mathbf{x})^t \phi(\mathbf{y})$;

● 特征空间中的内积都可以用核函数计算吗?

- 核函数的计算方式不是偶然的;
- 但并不是所有函数都可以作为核函数, 需要满足一定条件;

核函数

● 定理3.1（核函数）

- 令 \mathcal{X} 为输入空间， $\kappa(\cdot, \cdot)$ 是定义在 $\mathcal{X} \times \mathcal{X}$ 上的对称函数，则 κ 是核函数当且仅当对于任意数据 $D = \{\mathbf{x}_1, \dots, \mathbf{x}_m\}$ ，核矩阵 K 总是半正定矩阵：

$$K = \begin{pmatrix} \kappa(\mathbf{x}_1, \mathbf{x}_1) & \cdots & \kappa(\mathbf{x}_1, \mathbf{x}_m) \\ \vdots & \ddots & \vdots \\ \kappa(\mathbf{x}_m, \mathbf{x}_1) & \cdots & \kappa(\mathbf{x}_m, \mathbf{x}_m) \end{pmatrix}$$

- K 为半正定矩阵，当且仅当对于任意向量 \mathbf{v} ：

$$\mathbf{v}^t K \mathbf{v} \geq 0$$

- 半正定矩阵的特征值大于等于0；

核函数

● 常用核函数

线性核 $\kappa(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i^t \mathbf{x}_j$

多项式核 $\kappa(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i^t \mathbf{x}_j)^d$ $d \geq 1$ 为多项式的次数

高斯核 $\kappa(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\|\mathbf{x}_i - \mathbf{x}_j\|^2}{2\sigma^2}\right)$ $\sigma \geq 0$ 为高斯核的带宽

拉普拉斯核 $\kappa(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\|\mathbf{x}_i - \mathbf{x}_j\|}{\sigma}\right)$ $\sigma \geq 0$

Sigmoid核 $\kappa(\mathbf{x}_i, \mathbf{x}_j) = \tanh(\beta \mathbf{x}_i^t \mathbf{x}_j + \theta)$ $\beta > 0, \theta < 0$

双曲正切函数: $\tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}$

非线性的支持向量机

● 特征空间中的SVM

- 原始问题优化:

$$\min_{\mathbf{w}, b, \xi} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m \xi_i$$

subject to

$$y_i(\mathbf{w}^t \phi(\mathbf{x})_i + b) \geq 1 - \xi_i, \quad i = 1, \dots, m$$

$$\xi_i \geq 0, \quad i = 1, \dots, m$$

- 判别函数:

$$f(\mathbf{x}) = \mathbf{w}^t \phi(\mathbf{x}) + b$$

- 没有定义映射 ϕ , 特征空间中的向量 \mathbf{w} 无法直接求解;

非线性的支持向量机

● 特征空间中的SVM

○ 对偶问题优化:

$$\max_{\alpha} L(\alpha) = \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \phi(\mathbf{x}_i)^t \phi(\mathbf{x}_j)$$

subject to

$$\sum_{i=1}^m \alpha_i y_i = 0$$

$$C \geq \alpha_i \geq 0, \quad i = 1, \dots, m$$

○ 特征空间的权值向量: $\mathbf{w} = \sum_{i=1}^m \alpha_i \phi(\mathbf{x}_i)$

○ 判别函数:

$$f(\mathbf{x}) = \mathbf{w}^t \phi(\mathbf{x}) + b = \sum_{i=1}^m \alpha_i \kappa(\mathbf{x}, \mathbf{x}_i) + b$$







非线性SVM的优化求解

● 非线性SVM的优化求解方法







- 非线性SVM只能求解对偶问题，仍然是典型的二次凸优化，存在唯一解；；
- 与线性SVM的差别仅在于引入了核函数代替内积的计算；
- Matlab 2019中可以使用fitcsvm求解：

```
svm = fitcsvm( X,Z,'KernelFunction','rbf','KernelScale',0.1,...
    'BoxConstraint',1 );
Label = predict( svm,x );
```

非线性SVM的参数选择: σ


 $\sigma = 0.1, C = 1$

 $\sigma = 0.25, C = 1$

 $\sigma = 0.5, C = 1$

 $\sigma = 0.75, C = 1$

 $\sigma = 1, C = 1$

 $\sigma = 3, C = 1$

非线性SVM的参数选择: C



 $\sigma = 0.5, C = 0.1$

 $\sigma = 0.5, C = 1$

 $\sigma = 0.5, C = 10$

 $\sigma = 0.5, C = 100$

 $\sigma = 0.5, C = 1000$

 $\sigma = 0.5, C = 10000$

3.5 支持向量机回归

支持向量机回归

● 基本思路


- 在线性回归中使用 $\|\mathbf{w}\|^2$ 作为正则项；
- 损失函数中，允许预测值 $f(\mathbf{x})$ 与真实之间存在最大 ϵ 的误差，误差范围之内不计损失；



损失函数

• ϵ -不敏感损失函数

$$l_{\epsilon}(z) = \begin{cases} 0, & |z| \leq \epsilon \\ |z| - \epsilon, & \text{otherwise} \end{cases}$$



支持向量机回归

原始优化问题

- 在正负两端引入松弛变量 ξ_i 和 $\hat{\xi}_i$

$$\min_{\mathbf{w}, b, \xi, \hat{\xi}} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^m (\xi_i + \hat{\xi}_i)$$

subject to

$$\mathbf{w}^t \mathbf{x}_i + b - y_i \leq \epsilon + \xi_i,$$

$$y_i - (\mathbf{w}^t \mathbf{x}_i + b) \leq \epsilon + \hat{\xi}_i,$$

$$\xi_i \geq 0, \quad \hat{\xi}_i \geq 0, \quad i = 1, \dots, m$$

支持向量机回归

● 对偶优化问题

- 类似于分类问题，由Lagrange乘子法可以得到：

$$\max_{\alpha, \hat{\alpha}} \sum_{i=1}^m y_i (\hat{\alpha}_i - \alpha_i) - \sum_{i=1}^m \epsilon (\hat{\alpha}_i + \alpha_i) - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m (\hat{\alpha}_i - \alpha_i) (\hat{\alpha}_j - \alpha_j) \mathbf{x}_i^t \mathbf{x}_j$$

subject to

$$\sum_{i=1}^m (\hat{\alpha}_i - \alpha_i) = 0$$

$$C \geq \alpha_i, \hat{\alpha}_i \geq 0, \quad i = 1, \dots, m$$

支持向量机回归

● SVR的解

- 线性回归的权值向量 \mathbf{w} :

$$\mathbf{w} = \sum_{i=1}^m (\hat{\alpha}_i - \alpha_i) \mathbf{x}_i$$

- 根据Kuhn-Turker条件, 对应 $0 < \alpha_i < C$ 的数据 \mathbf{x}_i 刚好满足 $f(\mathbf{x}_i) = y_i + \epsilon$, 因此:

$$b = y_i + \epsilon - \sum_{j=1}^m (\hat{\alpha}_j - \alpha_j) \mathbf{x}_j^t \mathbf{x}_i$$

- 引入核函数 $\kappa(\cdot, \cdot)$, 非线性的SVR回归函数:

$$f(\mathbf{x}) = \sum_{i=1}^m (\hat{\alpha}_i - \alpha_i) \kappa(\mathbf{x}, \mathbf{x}_i) + b$$